

Expressions régulières et Automates

Dans tout ce TD, on repère par :

- (C) les exercices d'utilisation directe du cours (à savoir faire aisément et sans hésitation à la fin du chapitre).
- (*) les exercices d'application du cours (méthodes à connaître, objets à savoir manipuler).
- (**) les exercices intermédiaires (qui vous feront réfléchir en plus d'utiliser le cours).
- (***) les exercices difficiles.

(Il peut tout de même y avoir des questions faciles ou de cours dans des exercices plus difficiles (**), et quelques questions un peu plus délicates dans les exercices plus faciles (**).)

I - Expressions régulières

I.1 - Généralités sur les langages

Exercice 1

(**) Les **mots de Fibonacci** sur l'alphabet $\Sigma = \{a, b\}$ sont définis par :

$$f_0 = a, \quad f_1 = b \quad \text{et} \quad f_{n+2} = f_{n+1}f_n \text{ pour } n \geq 0.$$

1. Montrer que pour $n \geq 2$, le suffixe de longueur 2 de f_n est ba si n est pair, ab si n est impair.
2. Pour $n \geq 3$, on note g_n le préfixe de f_n obtenu en supprimant ses deux dernières lettres. Montrer que g_n est un palindrome.

Exercice 2

(**, un peu technique) Si L est un langage sur un alphabet Σ et u un mot de Σ^* , on définit le **résiduel à gauche** de L par u comme :

$$u^{-1}L = \{v \in \Sigma^* \mid uv \in L\}$$

On étend cette définition aux langages de la manière suivante :

$$K^{-1}L = \bigcup_{u \in K} u^{-1}L$$

Autrement dit, on a : $K^{-1}L = \{v \in \Sigma^* \mid \exists u \in K, uv \in L\}$.

1. Que vaut $\{\epsilon\}^{-1}L$ pour un langage L quelconque ?
2. Que vaut $K^{-1}\{\epsilon\}$ pour un langage K quelconque ?
3. A-t-on en général $L \subseteq K(K^{-1}L)$? Et $K(K^{-1}L) \subseteq L$?
4. Mêmes questions pour $K^{-1}(KL)$.

Exercice 3

 *Exercice arithmétique (***)*

Soient u, v deux mots non vides sur un alphabet Σ^* . Montrer l'équivalence des trois propriétés suivantes :

- (1) $uv = vu$
- (2) $\exists m, n \in \mathbb{N}^*, u^m = v^n$
- (3) $\exists w \in \Sigma^* \exists p, q \in \mathbb{N}, u = w^p \text{ et } v = w^q$

Pour l'implication (2) $\Rightarrow$ (3), on pourra considérer $d = \text{PGCD}(|u|, |v|)$ et utiliser le théorème des restes chinois.

Exercice 4

(*) Montrer que l'intersection de deux langages locaux est locale (sans condition sur les alphabets).

Exercice 5

(**) Montrer que si L est local, alors $\text{fact}(L)$ (ensemble des facteurs des mots de L) l'est également.

I.2 - Langages réguliers**Exercice 6**

(C) On considère l'alphabet $\Sigma = \{a, b\}$. Donner une description simple en français des langages dénotés par les expressions régulières suivantes :

1. $(\epsilon|\Sigma)(\epsilon|\Sigma)$;
2. $(\Sigma^2)^*$;
3. $(b|ab)^*(a|\epsilon)$;
4. $(ab^*a|b)^*ab^*$.

Exercice 7

(C) Donner des expressions régulières dénotant chacun des langages suivants :

1. les mots sur $\{a, b\}$ qui contiennent au plus un a ;
2. les mots sur $\{a, b\}$ qui contiennent au moins un a et au moins un b ;
3. les mots sur $\{a, b\}$ tels que toute série de a consécutifs soit de longueur paire;
4. les mots sur Σ (quelconque) dont la longueur n'est pas divisible par 3;
5. les mots sur $\{a, b\}$ contenant deux lettres consécutives égales;
6. les mots sur $\{a, b\}$ ne contenant pas deux lettres consécutives égales.

Exercice 8

(**)

Théorème 1

Lemme d'Arden :

Soient A et B deux langages sur un même alphabet Σ . On considère l'équation

$$X = AX \cup B$$

d'inconnue $X \subset \Sigma^*$.

- Le langage $L = A^*B$ est la plus petite solution de cette équation (au sens de l'inclusion).
- Si $\epsilon \notin A$, alors $L = A^*B$ est l'unique solution de l'équation.

Remarques :

- Il n'y a aucune hypothèse de rationalité sur les langages A et B . On peut toutefois remarquer que si A et B sont rationnels, il en est de même de $L = A^*B$.
 - Il sera plus agréable de noter $+$ au lieu de $|$ dans cet exercice, et de confondre expression régulière et langage associé : on parlera par exemple de l'équation $X = (a+b)X+c$, et l'on s'autorisera à écrire $a(b+c) = ab+bc$ au lieu de $a(b+c) \equiv ab+bc$ ou $\mathcal{L}(a(b+c)) = \mathcal{L}(ab+bc)$.
1. En appliquant le lemme d'Arden, résoudre l'équation $X = (a+b)X+c$.
 2. Quelle solution le lemme d'Arden fournit-il pour $X = (a+b+\epsilon)X+c$? Trouver une autre solution à cette équation.
 3. Démontrer le lemme d'Arden.

Exercice 9**(**) Fermeture transitive d'une relation :**Soit X un ensemble et $\mathcal{R} \subset X \times X$ une relation. On définit la **fermeture transitive de $\mathcal{R}$** par :– On définit $\mathcal{R}^n$ pour $n \geq 0$ par :

$$\begin{cases} x\mathcal{R}^0y \iff x = y \\ x\mathcal{R}^{n+1}y \iff \exists z \in X, x\mathcal{R}z \text{ et } z\mathcal{R}^ny \end{cases}$$

– On appelle *fermeture transitive* de $\mathcal{R}$ la relation

$$\mathcal{R}^+ = \bigcup_{n \geq 1} \mathcal{R}^n$$

– On appelle *fermeture transitive réflexive* de $\mathcal{R}$ la relation

$$\mathcal{R}^* = \bigcup_{n \geq 0} \mathcal{R}^n$$

Définition 1

- On considère la relation $\mathcal{R}$ sur $\mathbb{Z}$ définie par $n\mathcal{R}p$ si et seulement si $p = n + 1$. Donner une caractérisation simple de $\mathcal{R}^+$ et $\mathcal{R}^*$.
- Montrer que la fermeture transitive d'une relation $\mathcal{R}$ est la plus petite relation transitive contenant $\mathcal{R}$.
- On considère un graphe non orienté $G = (S, A)$ et la relation $\mathcal{R}$ sur V correspondante (i.e. $x\mathcal{R}y \iff \{x, y\} \in A$). Quelle est la structure du graphe dont la relation d'adjacence est donnée par $\mathcal{R}^+$?
- On considère à présent un graphe orienté $G = (S, A)$ et sa relation d'adjacence : $x\mathcal{R}y \iff (x, y) \in E$.
 - Donner une condition nécessaire et suffisante simple sur G pour que $\mathcal{R}^*$ soit une relation d'ordre.
 - Même question pour que $\mathcal{R}^*$ soit une relation d'ordre *totale*.
 - On considère un ordre topologique $\preceq$ sur G . Que peut-on dire de la relation $\preceq$ par rapport à la relation $\mathcal{R}^*$?

Exercice 10**(**) (HP) Expressions régulières étendues** (informatique pratique) :

- En OCaml, un littéral entier est :
 - soit une suite non vide de chiffres et de caractères `_` (littéral en base 10), où le premier caractère est nécessairement un chiffre ;
 - soit de la forme `0bx...x` ou `0Bx...x`, où `x...x` est une suite non vide de `0`, de `1` et de `_` ne commençant pas par un `_` (littéral en binaire) ;
 - soit un littéral en octal (on remplace `b` par `o` et les chiffres varient entre `0` et `7`) ;
 - soit un littéral en hexadécimal (on remplace `b` par `x` et les chiffres peuvent prendre les valeurs `0` à `9`, `A` à `F` et `a` à `f`).

De plus, dans tous les cas, le littéral peut éventuellement être précédé d'un signe `-` ou `+`.

Proposez une expression régulière en syntaxe concrète traduisant ces règles.

- Une adresse IPv4 est constituée de 4 octets, normalement représentés comme 4 nombres entre 0 et 255 séparés par des points : par exemple `10.10.192.68` mais aussi `057.254.003.1`. Proposer une expression régulière reconnaissant une telle adresse, d'abord sans respecter la contrainte « entre 0 et 255 », puis en la respectant.
- Proposer une regex étendue correspondant aux *carrés* sur l'alphabet $\{a, b\}$, c'est-à-dire à l'ensemble $\{u^2 \mid u \in \{a, b\}^*\}$.

Exercice 11Les mots croisés de regex suivants sont issus du site : <https://regexcrossword.com>.

Allez donc y faire un tour pour vous entraîner si le sujet vous intéresse et que vous bloquez sur les deux grilles complexes ci-dessous (n'y passez pas trop de temps, c'est HP).

-

(EG BEEE) [W Q] *					
(WE GA AL) T*Q+					
[HAS] *(SN PA)					
(.) T*E*\1					
[ABC] *(.) \1 (ME UD)					
[QA] . [WEST] *					
(HE RT TK) *.					
(RE QR) [QUART] *					
[EUW] *S[RITE] *					
(.) (.) \2 \1 [WE]					

2.

[OH] (PR AX TR) +					
(KT AL ET) +G					
(MN BO FI) [EU] {2,}					
(BG ON KK) + [RIF] +					
[RUTH] *(OE EO) [RB] *					
[IT] (O) *(BE AD) *\1					
[NORMAL] +T{2}					
. *(XA BE) . *					
(EG UL) 2 [ALF] *					
[REQ] *(G P) (.) +					

II - Automates

Exercice 12

(*) Donner un automate pour le langage

$$\{x \in \{0, 1\}^* \mid x \text{ code en binaire un entier divisible par 3}\}$$

On commencera par une version acceptant les zéros en tête (reconnaissant donc $\epsilon, 00, 0011, 01001, 110, \dots$) puis on donnera une version n'acceptant que les représentations canoniques ($\epsilon, 11, 110, 1001, 1100, 1111, \dots$).

Exercice 13

(C) On considère l'automate suivant :




FIGURE I.1 – L'automate A_2 .

1. Par la méthode de votre choix, par exemple simplement en "lisant" l'automate, donner une expression rationnelle correspondant au langage de cet automate.
2. Trouver une expression rationnelle correspondant en utilisant la méthode d'élimination des états. Vérifier qu'elle est équivalente à l'expression précédente.

Exercice 14

(*, mais technique) Soit $A = (\Sigma, Q, I, F, \delta)$ un ϵ -AFND.

1. A-t-on en général $\delta^*(q, aw) = E(\delta^*(\delta(q, a), w))$?
2. Montrer que pour tous mots $u, v \in \Sigma^*$ et toute partie $X \subset Q$, on a $\delta^*(X, uv) = \delta^*(\delta^*(X, u), v)$.

Les deux questions sont indépendantes.

Exercice 15

(**) **Fermeture arrière :**

La méthode d'élimination des ϵ -transitions donnée dans le cours est dite **par fermeture avant**. On peut aussi procéder par **fermeture arrière** en posant $\eta(q, a) = \delta(E(q), a)$. Que faut-il alors choisir comme ensemble d'états initiaux et acceptants pour obtenir un automate équivalent ? On rédigera la démonstration d'équivalence.

Exercice 16

(*) On définit :

- le **miroir** d'un mot w , noté $\bar{w}$, par
$$\begin{cases} \bar{\epsilon} = \epsilon \\ \overline{a_1 \dots a_n} = a_n \dots a_1 \end{cases}$$
- le miroir d'un langage $\mathcal{L}$ par $\bar{\mathcal{L}} = \{\bar{w} \mid w \in \mathcal{L}\}$

Montrer que si $\mathcal{L}$ est reconnaissable, alors $\bar{\mathcal{L}}$ l'est également.

Exercice 17

(C) Donner un automate fini avec ϵ -transition possédant un unique état initial et reconnaissant le langage dénoté par :

1. $a^*b^*c^*$;
2. $(a|b|c)^*(ab|aba|ca)^*$
3. $a(b|ba)^*(a|c)$

Exercice 18

(*) (technique) Déterminer l'automate de Thompson associé à l'expression régulière $(a|c)^*(abb|\epsilon)$ puis éliminer ses ϵ -transitions.


Exercice 19

(C) Déterminer l'automate de Glushkov associé à l'expression régulière $(a|c)^*(abb|\epsilon)$.

Exercice 20

(**) L'objectif de cet exercice est de montrer qu'il existe des automates non déterministes dont les automates déterministes équivalents sont tous de taille exponentielle en la taille de l'automate d'origine. Autrement dit, **le meilleur automate non déterministe peut être exponentiellement plus petit que le meilleur automate déterministe**.

On considère l'automate $\mathcal{A}_n$ suivant :



1. Quel est le langage reconnu par cet automate ?
2. Appliquer la procédure de déterminisation à cet automate pour $n = 1$.
3. En faire de même pour $n = 2$.
4. Combien d'états obtient-on dans le cas général quand on détermine cet automate ?
5. Montrer que l'automate déterminisé obtenu est minimal, c'est-à-dire qu'aucun automate déterministe possédant strictement moins d'état ne reconnaît le même langage.

Exercice 21

Pour chacun des problèmes suivants, donner les grandes lignes d'un algorithme permettant de le résoudre. On ne rentrera pas dans les détails, mais on essaiera de donner une solution raisonnablement simple et efficace.

1. Étant donné un mot t une expression régulière, déterminer si le mot appartient au langage dénoté par l'expression.
2. Déterminer si le langage reconnu par un automate est fini.
3. Déterminer si le langage dénoté par une expression régulière est fini.
4. Déterminer si le langage dénoté par une expression rationnelle e dénote $\emptyset$.
5. Déterminer si le langage reconnu par un automate est vide.
6. Déterminer si une expression régulière sur l'alphabet Σ dénote le langage Σ^* .
7. Déterminer si deux expressions régulières dénotent le même langage.

III - Langages et automates**Exercice 22**

(**) On considère un alphabet Σ et des langages L, L' sur Σ . Démontrer les propositions suivantes si elles sont vraies, donner un contre-exemple sinon.

1. Si L est rationnel et $L \cap L'$ ne l'est pas, alors L' n'est pas rationnel.
2. Si L est rationnel et si L' ne l'est pas, alors $L \cap L'$ n'est pas rationnel.
3. Si L est rationnel, alors L^* est rationnel.
4. Si L^* est rationnel, alors L est rationnel.
5. Si L et L' sont rationnels, alors $L \setminus L'$ l'est également.
6. Si LL' est rationnel, alors L est rationnel ou L' est rationnel.

III.1 - Langages rationnels**Exercice 23**

(*) Pour un langage L , on note $pref(L)$ l'ensemble des préfixes des mots de L , $suff(L)$ l'ensemble des suffixes, $fact(L)$ l'ensemble des facteurs. Montrer que si L est rationnel, ces trois langages le sont également.

Exercice 24

(**) On définit la **racine carrée** d'un langage L sur un alphabet Σ par :

$$\sqrt{L} := \{u \in \Sigma^* \mid uu \in L\}$$

1. Il y a six inclusions possibles entre les langages L , $\sqrt{L^2}$ et $(\sqrt{L})^2$. Déterminer lesquelles de ces inclusions sont vérifiées pour un langage L quelconque (on donnera une démonstration ou un contre-exemple suivant les cas).

Pour un automate fini déterministe complet $A = (Q, \Sigma, q_0, F, \delta)$, on considère les automates finis A'_q (pour $q \in Q$) tels que :

- les états de A'_q sont les couples $(q_i, q_j) \in Q^2$;
 - l'état initial de A'_q est (q_0, q) ;
 - les états terminaux de A'_q sont les (q, q_f) avec $q_f \in F$;
 - tous les A'_q ont la même fonction de transition δ' définie par $\delta'((q_i, q_j), a) = (\delta(q_i, a), \delta(q_j, a))$ (pour $a \in \Sigma$);
2. Donner une caractérisation simple du langage $\mathcal{L}(A'_q)$.
 3. En déduire que la racine carrée d'un langage rationnel est rationnelle.

Exercice 25

(**) On définit $\frac{1}{2}L = \{u \in \Sigma^* \mid \exists v \in \Sigma^*, |v| = |u| \text{ et } uv \in L\}$. Montrer par une construction similaire à celle de l'exercice précédent que si L est rationnel, alors $\frac{1}{2}L$ l'est également.

Exercice 26

(**) Pour deux langages L et K sur un même alphabet Σ , on définit :

$$K^{-1}L = \{v \in \Sigma^* \mid \exists u \in K, uv \in L\}$$

Montrer que si L est rationnel, alors $K^{-1}L$ l'est également (sans hypothèse sur K).

Exercice 27

(**) On définit le **produit de mélange** (*shuffle product* en anglais) de deux mots u et v sur Σ par

$$u \star v = \{u_1 \cdot v_1 \cdot \dots \cdot u_n \cdot v_n \mid \text{les } u_i \text{ et } v_i \text{ sont des mots tels que } u = u_1 \cdot \dots \cdot u_n \text{ et } v = v_1 \cdot \dots \cdot v_n\}$$

On remarquera bien que rien n'empêche certains des u_i et v_i d'être vides.

On étend cette définition aux langages en posant :

$$L \star L' = \bigcup_{u \in L \text{ et } v \in L'} u \star v$$

1. Déterminer $aa \star cd$.
2. Déterminer $|(u \star v)|$ en fonction de $|u|$ et $|v|$ dans le cas où les lettres de u et de v sont deux à deux distinctes.
3. Déterminer $\mathcal{L}(a^*) \star \mathcal{L}(b^*)$ et $\mathcal{L}(a^*) \star \mathcal{L}(bc)$.
4. Montrer que si L et L' sont rationnels, alors $L \star L'$ l'est également.
5. (difficile ***) On modifie maintenant $\star$ en opération $\star_1$ définie par :

$$u \star v = \{u_1 \cdot v_1 \cdot \dots \cdot u_n \cdot v_n \mid \text{les } u_i \text{ et } v_i \text{ sont des lettres telles que } u = u_1 \cdot \dots \cdot u_n \text{ et } v = v_1 \cdot \dots \cdot v_n\}.$$

Montrer que si L et L' sont rationnels, alors $L \star_1 L'$ (défini comme précédemment avec $\star_1$) est rationnel.

III.2 - Langages non rationnels et lemme de l'étoile

Exercice 28

(*) Soit Σ un alphabet contenant au moins deux lettres. Montrer que le langage des palindromes sur Σ (c'est-à-dire des mots égaux à leur miroir) n'est pas rationnel.

Exercice 29

(*) Montrer que le langage $\mathcal{P} = \{a^p \mid p \text{ premier}\}$ n'est pas rationnel.

Exercice 30

(**) Montrer que le langage L défini ci-dessous n'est pas rationnel, mais qu'il vérifie le lemme de l'étoile :

$$L = \{ab^r c^r \mid r \geq 0\} \cup \{a^r b^s c^t \mid r \neq 1, s \geq 0, t \geq 0\}.$$

IV - Automate minimal (HP)

Exercice 31

(**, mais HP) Soit $A = (\Sigma, Q, q_0, F, \delta)$ un automate fini déterministe complet.

Définition 2

Pour tout $q \in Q$, on définit le langage L_q associé à q par :

$$L_q = \{u \in \Sigma^* \mid \delta^*(q, u) \in F\}$$

Autrement dit, ce sont les mots reconnus par A en partant du sommet q . Si u est un mot tel que $q = \delta^*(q_0, u)$, alors on a $L_q = u^{-1}L$.

1. Calculer le langage L_q associé à chacun des états q de l'automate ci-dessous.
2. En déduire l'automate minimal équivalent.

